读入包

```
In [1]: import jieba #分词
import pandas as pd #处理dataframe
from gensim.models import Word2Vec #文本量化,词语-->向量
from sklearn.linear_model import LinearRegression #线性回归运算
from sklearn.model_selection import train_test_split #分训练和验证
data
import matplotlib.pyplot as plt #画图
import numpy as np #代数运算
import collections
from operator import itemgetter
```

读入数据

```
In [2]: SEM=pd.read_csv("/clubear/Lecture 6.3 - NLP - SEM Keyword Predic
    tion/SEM.csv")
    SEM
```

Out[2]:

	kw	logImp
0	1.5折机票	2.302585
1	10.1机票	1.609438
2	10.1机票查询	1.791759
3	10.1特价机票	1.568616
4	10月份特价机票	2.036882
4836	最低折扣机票	3.786373
4837	最低折扣机票查询	2.826656
4838	最好的机票网站	1.845827
4839	最好的机票预订网站	1.386294
4840	最优惠机票	1.945910

4841 rows × 2 columns

分词和分词处理

```
In [3]: wdtrain=[];wdlist=[]
for kw in SEM.kw: #按照每一行 (每一个样本) 用jieba进行分词
wd=jieba.lcut(kw)
wdtrain.append(wd) #append是list
wdlist=wdlist+wd #+是直接加在后面

Building prefix dict from the default dictionary ...
Loading model from cache /tmp/jieba.cache
Loading model cost 0.798 seconds.
Prefix dict has been built successfully.
```

得到的wdtrain是一个包含每个样本量分词的list的list, wdlist是一个所有分词的集合。

```
In [4]: tab=collections.Counter(wdlist) #找出每个分词出现的次数并以dictionar y的方式储存

df = pd.DataFrame.from_dict(tab,orient="index").reset_index() #
重新设置index

df = df.rename(columns={'index':'kw', 0:'count'}) #添加count col umn,重新以kw为index

df = df.sort_values(by='count',ascending=False) #按照分词出现的数量进行排序
```

```
In [5]: ncov=len(df.kw) #分词数量
topkw=list(df.kw) #所有分词
mydict=dict.fromkeys(topkw) #会造一个value是空的字典
for i in range(ncov):
    mydict[topkw[i]]=i #在字典分词变为整数,从0开始到ncov结束
mydict
```

```
Out[5]: {'机票': 0,
         '飞机票': 1,
         '特价机票': 2,
         '杳询': 3,
         '预订': 4,
         '便宜': 5,
         '-': 6,
         '打折': 7,
         '特价': 8,
         '到': 9,
         '深圳': 10,
         '北京': 11,
         '航班': 12,
         '广州': 13,
         '的': 14,
         '上海': 15,
         '网站': 16,
         '预定': 17,
         '网': 18,
         '订': 19,
         '飞机': 20,
         '网上': 21,
         '订机票': 22,
         '机票价格': 23,
```

```
'辽宁': 464,
         '临沧': 465,
         '售票': 466,
         '哪有': 467,
         '那拉提': 468,
         '南方航空公司': 469,
         '平价': 470,
         '七天': 471,
         '青春': 472,
         '机': 473,
         '那网': 474,
         '能': 475,
         '三峡': 476,
         '凤凰': 477,
         '三折': 478,
         '厦航': 479,
         '厦门航空公司': 480,
         '库车': 481,
         '京东': 482,
         '湖南': 483,
         '卡': 484,
         '风景区': 485,
         '注意事项': 486,
         '亲子': 487,
         '惠州': 488,
         '比价': 489,
         '采购': 490,
         '东航': 491,
         '呢': 492,
         '及': 493,
         '定购': 494,
         '江西': 495,
         '附加费': 496,
         '묵': 497,
         '货到付款': 498,
         '酒店': 499,
         '票号': 500,
         '搜索': 501,
         '可信': 502,
         '早订': 503,
         '江苏': 504,
         '舟山': 505}
In [6]: |ss=len(SEM.kw) #sample size 样本量
       ncov=len(mydict) #分词数量
        X=np.zeros([ss,ncov+1]) #生成一个x的0-1矩阵。如果一个关键词包含相应词根
        ,那么对应的x元素取值为1,否则为0
        for i in range(ss):
           columnID=itemgetter(*wdtrain[i])(mydict)
           X[i,columnID]=1
           X[i,ncov]=len(SEM.kw[i])
```

```
ncov
In [18]:
Out[18]: 506
In [7]:
Out[7]: array([[1., 0., 0., ..., 0., 0., 6.],
                [1., 0., 0., ..., 0., 0., 6.],
                [1., 0., 0., ..., 0., 0., 8.],
                [1., 0., 0., ..., 0., 0., 7.],
                [1., 0., 0., ..., 0., 0., 9.],
                [0., 0., 0., ..., 0., 0., 5.]])
In [8]: | DIM=100
         #然后做一个word2vec模型
         wvmodel = Word2Vec(wdtrain, size=DIM, min count=1) # size表示词向
         量的大小,min count表示最少的词频,低于此词频的词会被忽略掉
         Z=np.zeros([ss,DIM])
         for i in range(ss):
             vec=wvmodel[wdtrain[i]]
             Z[i,:]=np.mean(vec,0)
         /root/miniconda3/envs/myconda/lib/python3.7/site-packages/ipyke
```

/root/miniconda3/envs/myconda/lib/python3.7/site-packages/ipyke rnel_launcher.py:6: DeprecationWarning: Call to deprecated `__g etitem___` (Method will be removed in 4.0.0, use self.wv.__getit em () instead).

线性回归模型分析

把word2vect学习出来的空间坐标的平均值作为一个新的解释性变量Z与前面的X整合,形成新的矩阵 XZ,然后做Y对XZ的回归分析,并检测外样本预测精度,外样本的预测精度其实是非常不稳定的,充满了异常值。因此,没有用均值,而是采用的中位数。

Out[11]: 74.96

可以得到线性回归模型的MedSE的中位数是74.96

用深度学习模型

从网上了解到Sequential比较适合做Text分析

Using TensorFlow backend.

Model: "sequential_1"

Output	Shape		Param #
======	=====		======
(None,	None,	100)	50600
(None,	None,	128)	64128
(None,	128)		0
(None,	10)		1290
(None,	1)		11
	(None, (None, (None,		(None, None, 100) (None, None, 128) (None, 128) (None, 10)

Embedding的参数: 100 506 = embedding_dim ncov

Conv1D的参数: (100 5 +1) 128 = 501 128 = 64128, 其中5是kernel size, 100是上一层遗留通道

数,128是卷积核个数。

Dense1的参数: 128 10 + 10 = 1290

Dense2的参数: 10 * 1 + 1 = 11

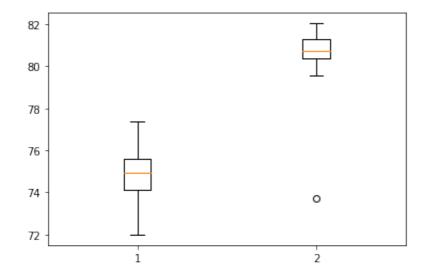
Train on 2420 samples

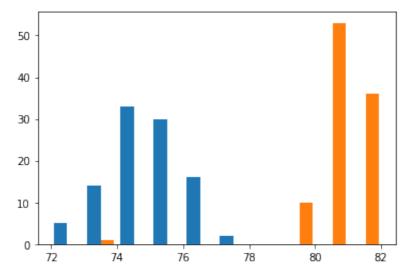
ss: 0.1422 - accuracy: 0.0000e+00

```
Train on 2420 samples
      loss: -21904105.6992 - accuracy: 0.0000e+00
      Train on 2420 samples
      2420/2420 [============= ] - 1s 312us/sample -
      loss: -19443080.4661 - accuracy: 0.0000e+00
      Train on 2420 samples
      loss: -22608493.5116 - accuracy: 0.0000e+00
      Train on 2420 samples
      2420/2420 [============ ] - 1s 284us/sample -
      loss: -20121038.2678 - accuracy: 0.0000e+00
      Train on 2420 samples
      loss: -19858205.7587 - accuracy: 0.0000e+00
      Train on 2420 samples
      2420/2420 [============ ] - 1s 275us/sample -
      loss: -20319463.5041 - accuracy: 0.0000e+00
      Train on 2420 samples
      2420/2420 [============] - 1s 295us/sample -
      loss: -23118365.3521 - accuracy: 0.0000e+00
In [15]: np.round(np.median(R22),2)
Out[15]: 80.73
```

用深度学习模型得到的MedSE的中位数是80.73

```
In [16]: plt.boxplot((R21,R22))
```





In []: